


สถาปัตยกรรม AI ส่วนกลาง: คู่มือติดตั้ง 9Router บน Docker และ Cloud VPS

พิมพ์เขียวเชิงกลยุทธ์สำหรับการบริหารจัดการ AI Orchestration Layer สำหรับ Cloud
Architects และ AI DevOps



การเปลี่ยนผ่านสู่ระบบศูนย์กลาง (The Centralized Paradigm)

รูปแบบเดิม (Local/Individual):



ความปลอดภัย: กระจาย API Keys ไว้ตามเครื่องบุคคล (ความเสี่ยงสูง)



ความเสถียร: ขึ้นอยู่กับประสิทธิภาพเครื่องและเครือข่ายส่วนบุคคล



ข้อจำกัด: พึ่งพาผู้ให้บริการรายเดียว (Vendor Lock-in)

สถาปัตยกรรมใหม่ (Centralized Router บน Cloud):



ความปลอดภัย (API Aggregation): รวม API Keys ไว้ใน Vault ที่ปลอดภัยจุดเดียว




ความพร้อมใช้งาน (High Availability): เข้าถึงได้จากทุกที่ (Anywhere Access) ผ่านสภาพแวดล้อมที่เสถียร




ความยืดหยุ่น: รองรับ Multi-Model Failover และกระจายโหลดอัตโนมัติ

โครงสร้าง Orchestration Layer แบบ End-to-End



การจัดสรรทรัพยากร: จุดสมดุลของระบบ (The "Sweet Spot")




RAM 8 GB: หัวใจหลักของระบบ จำเป็นอย่างยิ่งสำหรับการทำ Queue Management และ Caching ข้อมูล เพื่อให้การสลับโมเดลไร้รอยต่อ

CPU 2 Cores: ป้องกันปัญหาคอขวด (Bottleneck) เมื่อระบบต้องรองรับ Parallel Requests จากทีมพัฒนา

Storage & Bandwidth: 100 GB NVMe และ 8 TB Bandwidth เพียงพอต่อการขยายตัว

Deployment: รองรับ 1-Click Provisioning ผ่าน Hostinger Application Template

การป้องกันความปลอดภัยของ Dashboard (Keys to the Kingdom)



กลยุทธ์ Multi-Model และการลด Vendor Lock-in


Free Tier (Internal/Ready-to-use)



Open Code Free



GPT-9



Kiro AI, Mimo
(แนะนำทดสอบ M spark)

โมเดลเป้าหมาย: Open Code Free, GPT-9, Kiro AI, Mimo (แนะนำทดสอบ M spark)

Use Case: งาน Routine, การเขียน Unit Test, Boilerplate Code

ข้อดี: ความเร็วสูง, ไม่มีค่าใช้จ่ายต่อ Token

Premium Tier (Bring Your Own Key - BYOK)



Anthropic



GLM Coding




Alibaba

โมเดลเป้าหมาย: Anthropic, GLM Coding, Alibaba

Use Case: งานที่ต้องการ Logic และ Reasoning ขั้นสูง

ข้อดี: ความเสถียรสูงสุด, รองรับ Context ขนาดใหญ่

ระบบ Failover อัตโนมัติ (Zero-Downtime Engine)



Cost-Efficiency First:

หลักการจัดเรียงโดยวางโมเดล Free Tier ที่ความเร็วสูงไว้ลำดับต้น และโมเดล Premium ที่เสถียรสูงสุดไว้ลำดับท้าย

Logical Grouping:

กำหนดชื่อกลุ่ม (เช่น MyCombo) โดยต้องตั้งชื่อแบบ Case-sensitive เพื่อใช้เชื่อมต่อกับ Client


Auto-Cascade:

หากผู้ให้บริการรายแรกล่ม ระบบจะส่ง Request ไปยังโมเดลสำรองในเสี้ยววินาที ทำให้ Workflow ไม่สะดุด

การเตรียมโครงสร้างพื้นฐานระดับระบบไฟล์ (Directory Structure)

 9router-docker/

 nginx/

 default.conf (ตั้งค่า Reverse Proxy)

 data/ (Persistent Volume สำหรับ 9Router)

 npm/ (ข้อมูลและ Let's Encrypt สำหรับ SSL)

 docker-compose.yml (ไฟล์ Orchestration หลัก)

การจัดการกราฟฟิคด้วย Nginx Reverse Proxy

```
location / {
```

```
    proxy_pass http://9router-app:3000;
```

```
    proxy_http_version 1.1;
```

```
    proxy_set_header Upgrade $http_upgrade;
```

```
    proxy_set_header Connection 'upgrade';
```

```
    proxy_set_header X-Real-IP $remote_addr;
```

```
}
```


proxy_pass: ส่งต่อ Traffic จากพอร์ต 80 ไปยัง 9Router Container

Upgrade \$http_upgrade: จำเป็นอย่างยิ่งสำหรับการรักษาการเชื่อมต่อ WebSockets ให้คงที่ระหว่าง AI Streaming

X-Real-IP: ส่ง Header ระบุ IP จริงของ Client เพื่อประโยชน์ในการทำ Audit Log

การเชื่อมโยงคอนเทนเนอร์ด้วย Docker Compose

```
services:
  9router:
    ports:
      - '20128:20128'
    volumes:
      - ./data:/app/data
    environment:
      - INITIAL_PASSWORD=123456
  nginx-proxy-manager:
    ports:
      - '80:80'
      - '81:81'
      - '443:443'
```



Port Mapping: เปิดพอร์ต 20128 สำหรับ 9Router และพอร์ตมาตรฐาน Web/SSL (80, 443, 81) สำหรับ Nginx

Data Persistence: ทำ Volume Mapping (./data:/app/data) เพื่อไม่ให้เกิดการสูญหายเมื่อรีเซ็ตคอนเทนเนอร์

Environment: กำหนดรหัสผ่านเริ่มต้นผ่านตัวแปร INITIAL_PASSWORD

การสั่งรันระบบและตรวจสอบสถานะ (Deployment & Verification)

\$ docker compose up -d

(ดาวน์โหลด Image และรัน Container ใน Background Mode)

\$ docker compose ps

(ตรวจสอบสถานะการทำงานของบริการทั้งหมดใน Network)

\$ docker compose logs -f nginx

(ดักจับ Log แบบ Real-time เพื่อตรวจสอบกราฟฟิคหรือข้อผิดพลาด)

เปิดเว็บเบราว์เซอร์และระบุ IP Address หรือ Domain เพื่อเข้าสู่หน้า Dashboard

การเชื่อมต่อฝั่งไคลเอนต์: Claude Code Integration

.claude/settings.json

```
{
  'env': {
    'ANTHROPIC_BASE_URL': 'http://<VPS_IP>:20128/v1',
    'ANTHROPIC_DEFAULT_OPUS_MODEL': 'MyCombo'
  }
}
```

VPS Server

MyCombo
Logic

Network
Boundary

Routing Override:

การเซ็ต ANTHROPIC_BASE_URL
บังคับให้ Traffic ส่งมายัง Proxy ส่วนกลาง
แทนที่จะวิ่งตรงไปที่ Anthropic

Targeting the Engine: ส่วน

ANTHROPIC_DEFAULT_OPUS_MODEL
ให้ตรงกับชื่อ Combo ที่สร้างไว้แบบ Case-
sensitive เพื่อถึงลอจิก Failover มาใช้งาน


การยกระดับความปลอดภัยด้วย SSL (HTTPS)



Nginx Proxy Manager


- **Future-proofing Security:** สถาปัตยกรรมระดับองค์กรต้องมีการเข้ารหัสข้อมูลระหว่าง Client และ VPS
- **Automated Certificates:** แนะนำให้ใช้เครื่องมือที่ติดตั้งมาพร้อมกันอย่าง Nginx Proxy Manager (ผ่านพอร์ต 81)
- **Let's Encrypt Integration:** จัดการสร้างและต่ออายุ SSL Certificate ได้โดยอัตโนมัติ ไม่ต้องตั้งค่าผ่าน Command Line ด้วยตนเอง

การสังเกตการณ์ (Observability) และความคุ้มค่า (ROI)



Usage Observability:	Resource Sharing:	Data-driven Scaling:
ติดตามการบริโภค Token แบบ Real-time วิเคราะห์ พฤติกรรมการเรียกใช้งานโมเดล ของทีมเพื่อประเมิน ROI	ลดความซ้ำซ้อนของการสมัคร Subscription ราคาแพง ทีมพัฒนาทั้งหมดสามารถแชร์ Resource จาก API Key องค์กรชุดเดียวกัน	ใช้ข้อมูล Usage จริงเพื่อวางแผน ขยายสเปกของ Hostinger VPS ในอนาคต

บทสรุป: สภาพแวดล้อมการพัฒนาที่ยืดหยุ่น (Resilient Environment)



ไม่ใช่แค่การลดต้นทุน แต่คือการสร้างรากฐาน AI Infrastructure ที่มั่นคงสำหรับองค์กร