


9Router: โครงสร้างพื้นฐานอัจฉริยะสำหรับการเขียนโค้ดด้วย AI

> เริ่มต้นระบบฟรีอ็อกซี ข้ามขีดจำกัด เพิ่มประสิทธิภาพโทเคน




ความยุ่งยากของการเชื่อมต่อตรงสู่ API




การเผาผลาญโทเคน

ผลลัพธ์จากเครื่องมือที่ไม่ได้ปรับแต่ง
จะกลืนกินงบประมาณพร้อมท์ของคุณอย่างรวดเร็ว



โควตาที่สูญเปล่า



แพ็คเกจรายเดือนราคาแพงหมดอายุ
ไปในขณะที่คุณไม่ได้ใช้งาน



ติดขัดการทำงาน


การเขียนโค้ดหยุดชะงักทันที
เมื่อผู้ให้บริการจำกัดอัตราการใช้งาน (Rate Limit)

เปลี่ยนจากการเชื่อมต่อตรง สู่ระบบเราเตอร์อัจฉริยะ




- **ระบบพรีอักษิในเครื่อง:**
คั่นกลางระหว่างเครื่องมือ CLI ของคุณและ LLMs อย่างไร้รอยต่อ
- **รองรับทุกรูปแบบ:**
แปลงรูปแบบ OpenAI เป็น Claude, Gemini หรือ Endpoint อื่นๆ อัตโนมัติ
- **จัดการอัตโนมัติ:**
ติดตามโควตาโทเคน และรีเฟรช OAuth แบบเรียลไทม์

เชื่อมต่อทุกเครื่องมือ สู่ทุกโมเดล



กลไกที่ 1: การบีบอัดข้อมูลเข้าอัจฉริยะ



ตัดทอนแบบไม่สูญเสียบริบท:
RTK ตรวจจับผลลัพธ์จาก
'git diff', 'grep', และ 'tree'
อัตโนมัติ

ผลลัพธ์ที่ได้:
ประหยัดโทเคนขาเข้า **20-40%**
ในทุกคำขอ โดยไม่เสียบริบทสำคัญ


ออกแบบมาให้ปลอดภัย:
หากการบีบอัดล้มเหลว ระบบจะส่ง
ข้อความต้นฉบับดั้งเดิมทันที

กลไกที่ 2: บังคับให้เขียนโค้ดกระชับ ตรงประเด็น (YAGNI-first)



Ponytail (Dev ชีเนียร์จอมขี้เกียจ)	Caveman Mode	ผลลัพธ์ที่ได้
แทรก System Prompt บังคับให้ LLM เน้นการลบโค้ด ใช้ไลบรารีมาตรฐาน และเขียนโค้ดบรรทัดเดียว	บังคับให้ใช้คำสื่อสารที่สั้นกระชับที่สุด แต่ยังคงรักษาความหมายทางเทคนิคอย่างครบถ้วน	ตอบสนองเร็วขึ้น ลดภาระการแก้ไขโค้ดด้วยตนเอง และประหยัดโทเคนขาออกสูงที่สุดถึง 65%

กลไกที่ 3: ระบบสลับเส้นทางสำรองอัจฉริยะ 3 ระดับ



ทำงานไม่มีสะดุด
(Zero Downtime):
ติดตามโควตาและเวลาหน่วง
(Cooldown) แบบเรียลไทม์

สลับอัตโนมัติ:
โยกย้ายกราฟฟิกร้อยต่อเมื่อ
โควตาหมดหรือ API ล่ม

รองรับหลายบัญชี:
กระจายโหลดแบบ Round-robin
ระหว่างหลายบัญชีในผู้ให้บริการ
เดียวกัน

ตารางวิเคราะห์กลยุทธ์ผู้ให้บริการ

แพ็คเกจรายเดือน (ระดับ 1)	สำรองราคาถูก (ระดับ 2)	ระบบนิเวศฟรี (ระดับ 3)
\$20–\$200/เดือน	\$0.20–\$0.60 ต่อ 1M	\$0
cc/claude-opus-4-7 cu/claude-4.6	glm/glm-5.1 (รีเซ็ตรายวัน) minimax/MiniMax-M2.7	kr/claude-sonnet-4.5 vertex/gemini-3.1-pro
งานหลักที่ซับซ้อน รีดประสิทธิภาพโควตาสูงสุด	ใช้งานล้นโควตาจากงานหลัก ในราคาประหยัด	การใช้งานสำรองฉุกเฉิน หรือเขียนโค้ดด้วยงบบุญบาท

ปลดล็อกระบบนิเวศ AI ฟรี

ค่าใช้จ่าย: \$0

Kiro AI

- **รายละเอียด:** ฟรี ~50 เครดิต/เดือน
- **โมเดล:** Claude 4.5, GLM-5, MiniMax
- **วิธีเข้าถึง:** OAuth ผ่าน AWS/Google ไม่ต้องใช้ API Key

ค่าใช้จ่าย: \$0

OpenCode Free


- **รายละเอียด:** ฟรีทุกซีแบบ ไม่ต้องยืนยันตัวตน
- **โมเดล:** ดึงโมเดลอัตโนมัติ จาก `opencode.ai/zen/v1/models`
- **วิธีเข้าถึง:** แค่เชื่อมต่อก็ เขียนโค้ดได้ทันที

ค่าใช้จ่าย: \$0

Vertex AI

- **รายละเอียด:** เครดิต GCP \$300 สำหรับบัญชีใหม่ (90 วัน)
- **โมเดล:** Gemini 3 Pro, DeepSeek, GLM-5
- **วิธีเข้าถึง:** ผ่าน Endpoint ของ Vertex AI Studio

เชื่อมต่อฮาร์ดแวร์ในเครื่องของคุณ (Local Hosting)



- ส่งข้อมูล Speech-to-Text, TTS, และ Embeddings ไปยังเครื่องของคุณเอง
- 9Router มองฮาร์ดแวร์ในเครื่องของคุณเป็นผู้ให้บริการรายหนึ่ง โดยใช้มาตรฐาน OpenAI
- กระจายโหลดข้ามเครื่อง Local หลายเครื่องได้ผ่านการตั้งค่า Connection Overrides

ภาพลวงตาบนแดชบอร์ด vs ความจริงของบิลค่าใช้จ่าย




- 9Router ใช้งานฟรี 100%: เป็นซอฟต์แวร์ Open-source ที่ไม่มีการตัดบัตรเครดิตคุณ
- ค่าใช้จ่ายที่เห็นคือตัวติดตามความคุ้มค่า: เมื่อใช้ Kiro, OpenCode หรือ Vertex ระบบจะแสดงจำนวนเงินที่คุณ 'ควรจะต้องจ่าย' หากใช้ API แบบเสียเงิน
- คุณจ่ายเงินให้แก่ผู้ให้บริการรายเดือนเท่านั้น 9Router เพียงช่วยบริหารกราฟฟิคให้คุ้มค่าที่สุด

การตั้งค่าแบบไหนที่เหมาะสมกับเวิร์กโฟลว์ของคุณ?

โปรไฟล์ผู้ใช้	คอมโบที่แนะนำ	ผลลัพธ์
ฉันมีแพ็คเกจ Claude Pro	Maximize Combo (`cc/claude-opus-4-7` + `glm/glm-5.1` เป็นตัวสำรอง)	ใช้โควตาคุ้มทุกหยด สลับไปใช้ ตัวสำรอง \$0.6/1M ได้แบบเนียน
ฉันต้องการงบประมาณ (\$0)	Free-Forever Combo (`kr/claude-sonnet-4.5` + `kr/glm-5` + `oc/<auto>`)	ได้ระดับโปรดักชันฟรี 100% + การประหยัดโทเคนจาก RTK
ฉันทำงานบนโปรเจกต์ ต้องใช้ AI 24/7	5-Layer Fallback (Claude Pro → GLM (\$0.6) → MiniMax (\$0.2) → Kiro (Free))	ระบบไม่มีทางล่มใน ทางคณิตศาสตร์
ฉันต้องการ AI ในแอปแชท	OpenClaw Integration (Kiro + OpenClaw Native)	ผู้ช่วย AI ฟรีใน WhatsApp/Slack/Telegram

ติดตั้งและใช้งานได้ทุกที่ในไม่กี่วินาที

Local CLI (ค่าเริ่มต้น)



```
npm install -g 9router && 9router
```

แดชบอร์ดจะเปิดขึ้นทันทีที่ `localhost:20128`

Docker Container



```
docker run -p 20128:20128 decolua/9router
```

อิมเมจรองรับทั้งระบบ linux/amd64 และ arm64

VPS / Server



ติดตั้งผ่าน PM2 หรือ CapRover เพื่อแชร์ Endpoint ของคุณให้ใช้งานได้ทั่วโลก

Cloud Sync



ซิงค์การตั้งค่า คีย์ และคอมโบข้ามอุปกรณ์
หลายเครื่องอย่างปลอดภัยด้วยระบบคลาวด์

ควบคุมโครงสร้างพื้นฐาน AI ของคุณอย่างสมบูรณ์แบบ

- หยุดสิ้นเปลืองโทเคน
- ทลายทุกขีดจำกัดการใช้งาน
- ใช้งานได้เนื่อง 24/7

```
> npm install -g 9router  
> Dashboard accessible at  
http://localhost:20128
```



ซอฟต์แวร์ Open source ใช้งานฟรีตลอดกาล เริ่มต้นเราต์กราฟฟิค AI ของคุณตั้งแต่วันนี้